

**Министерство науки и высшего образования Российской Федерации**
**Федеральное государственное бюджетное образовательное учреждение высшего образования**
**«Московский государственный технический университет имени Н.Э. Баумана**
**(национальный исследовательский университет)»**
**(МГТУ им. Н.Э. Баумана)**

ФАКУЛЬТЕТ Информатики и систем управления

КАФЕДРА Теоретической информатики и компьютерных технологий

# ОТЧЕТ ПО ПРОИЗВОДСТВЕННОЙ ПРАКТИКЕ

Студент Дьячков Егор Сергеевич

Группа ИУ9-41Б

Тип практики Технологическая

Название предприятия ПАО "Сбербанк России"

Студент _____ Дьячков Е.С.
*подпись, дата* *фамилия, и.о.*

Рекомендуемая оценка: _____
Руководитель практики
от предприятия: _____ Жиров Д.В.
*подпись, дата* *фамилия, и.о.*

Руководитель практики _____ Коновалов А.В.
*подпись, дата* *фамилия, и.о.*

Оценка _____

*2024 г.*

# Содержание

Содержание ..... 2
Введение ..... 3
Характеристика предприятия ..... 3
Отчет о проделанной работе ..... 6
Исследование возможности сопоставления номера телефона человека с регионом ..... 6
Анализ распределения возрастов клиентов по возрастным группам ..... 10
Заключение ..... 15

# Введение

Технологическая практика представляет собой важный этап в процессе обучения студентов, позволяющий им применить теоретические знания на практике и ознакомиться с реальными рабочими процессами в своей области.

Данный отчет представляет результаты технологической практики, осуществленной в рамках сотрудничества с Публичным акционерным обществом «Сбербанк России» в работе над задачей по выявлению синтетических данных среди реальных. Она имеет высокую актуальность для компании, работающей в банковской сфере, так как каждый день Сбербанк обрабатывает большое количество файлов, писем, сообщений и прочей информации, которая вместе составляет значительный объем данных. Среди них могут быть тестовые данные, таблицы для обучения моделей, а также реальные данные, которые не должны распространяться.

Основной целью практики была задача по определению синтетических данным. Для того, чтобы выполнить эту задачу, она была разбита на подзадачи. Часть из них представлена в данном отчете: исследование возможности сопоставления номера телефона человека с регионом, в котором он проживает и анализ распределения возрастов клиентов по возрастным группам.

Далее в отчете будет подробно раскрыт ход работы, показаны фрагменты кода и результаты работы для каждой подзадачи.

# Характеристика предприятия

Сбер — исторический преемник сберегательных касс Российской империи, а затем и советских Гострудсберкасс. Ниже — основные вехи его развития, тесно переплетённые с этапами становления страны.

12 ноября 1841 года император Николай I подписал указ об учреждении в России сберегательных касс «для доставления через то средств к сбережению верным и выгодным способом». Первые кассы открываются в 1842 году в

Санкт-Петербурге, Москве и Одессе. На сберегательных книжках печатается изображение кормящего птенцов пеликана как символ заботы о наименее обеспеченных людях.

Первым клиентом первой российской сберегательной кассы стал служащий Ссудной казны в Санкт-Петербурге Николай Кристофари. 1 марта 1842 года он открыл вклад на 10 рублей — максимально возможную в то время в сберкассах сумму. В Санкт-Петербурге и Москве ему установлены памятники, выражающие уважение Сбера к своим клиентам. К концу 1850-х годов вкладчиками сберкасс стали 90 тысяч человек.

16 октября 1862 г. император Александр II утвердил новый Устав сберегательных касс, по которому они должны были создаваться «во всех городах, посадах и местечках». В результате в России появилась сеть финансовых учреждений, доступных для всех сословий. К 1895 году было открыто 3875 касс, на вкладах хранилось 368 млн рублей. Это время называют эпохой расцвета сберегательного дела в России.

В 1895 году устав сберегательных касс снова изменён: правительство принимает на себя полную ответственность за сохранность вверенных кассам вкладов. В 1905 году кассы получили право выдавать страховые полисы. В 1902 году сберегательные кассы открываются практически повсюду. Были они и на кораблях военного флота, в том числе на знаменитых крейсерах «Варяг» и «Аврора».

После Октябрьской революции в 1919 году сберегательные кассы объединили с Народным банком РСФСР, а в 1925 году всю сеть преобразовали в Гострудсберкассы СССР. В период с 1922 по 1941 год в СССР были выпущены различные облигации государственных займов, которые активно размещались через сберкассы, а полученные средства направлялись на индустриализацию советского государства.

В годы Великой Отечественной войны сберкассы сыграли важную роль в распространении военных займов и приёме пожертвований в Фонд обороны.

Четыре военных займа под лозунгом «Всё для фронта, всё для победы!» собрали 72 млрд рублей. За счёт поступлений по займам покрыто 15% военных расходов. В послевоенное время сберкассы массово распространяют займы восстановления и развития народного хозяйства.

За тридцать лет количество сберегательных касс увеличилось вдвое: с 40 тысяч в 1951 г. до 79 тысяч в 1981. К началу 1986 года в них на 171 млн счетов хранились сбережения на сумму свыше 220 млрд рублей. После того как в 1963 году в сберкассах начали принимать коммунальные, налоговые, страховые и другие платежи, выдавать зарплату рабочим и служащим предприятий, их клиентами становятся практически все граждане СССР.

В 1987 году в ходе перестроечных реформ сберегательные кассы были реорганизованы в Сберегательный банк СССР. Начинается эмиссия банковских карт, появляются новые виды вкладов: срочные, молодёжные, на детей, накопительные. Сбербанк стал совершать обмен валюты, а в 1988 году открыл в Москве первый банкомат, ставший отправной точкой для самой большой в России сети устройств самообслуживания.

После ряда реорганизаций в 1991 году был зарегистрирован Сбербанк России. В 1996 году собрание акционеров приняло концепцию развития до 2000 года, нацеленную на его трансформацию в универсальный коммерческий банк. Сбербанк — ведущий участник рынка государственных ценных бумаг, крупный кредитор на рынке ссудных капиталов. Он выходит на международную арену, приобретая дочерний банк в Казахстане в 2006 году.

В ноябре 2007 года Президентом, Председателем Правления Сбербанка утверждён Герман Греф. Уже в следующем году Наблюдательный совет одобрил концептуально новую стратегию развития, которая радикально изменила облик крупнейшего банка страны и предопределила его дальнейшую трансформацию в высокотехнологичную структуру, способную конкурировать с финтехом.

В условиях пандемии Сбер определяет главную задачу: максимально помочь клиентам и государству. Он становится масштабным проводником

государственных программ поддержки населения и бизнеса, предлагая и собственные решения. Сервисы телемедицины Сбера внедряются по всей стране, его ИТ-платформа используется для предоставления государственных услуг и создания высокотехнологичных экономик субъектов Российской Федерации.

## Отчет о проделанной работе

### Исследование возможности сопоставления номера телефона человека с регионом

Для выполнения были поставлены следующие задачи:

1. Изучить формат номера телефона
2. Проверить формат
3. Собрать данные о кодах регионов
4. Определить место жительства по коду региона в номере телефона
5. Проанализировать результат и построить визуализацию данных
6. Реализовать метод

Согласно сформулированным задачам вначале был изучен формат номера телефона. Международный Консультационный Комитет по Телефонии и Телеграфии разработал рекомендации E.123 E.164, согласно которым устанавливаются номера. Первым правилом является то, что все номера в международном формате начинаются со знака «+» без исключения. После знака «+» идут цифры, которые указывают страну, они называется кодом страны. Длина этой комбинации может доходить до 6 цифр, но обычно она занимает одну, две или три цифры. Целью создания данных кодов было присвоение каждой стране уникального номера. Было принято решение поделить весь мир на 9 частей в соответствии с географической принадлежностью страны, код страны будет начинаться на эту цифру. На момент создания этой системы еще

существовал СССР и было принято решение выделить отдельный код +7 для всего СССР, после распада, данный номер сохранился только в России и Казахстане. После кода страны идет уже сам номер телефона. Таким образом, для каждой страны хватает номеров на каждого человека проживающего в этой стране. Данного количества достаточно даже Китаю и Индии с 1.5 миллиардов населения. У каждой страны есть примерно по 10 миллиардов номеров. Правительство самостоятельно решает, как распоряжаться этими номерами и кому их выдавать, Но в рекомендациях E.123 E.164 советуют использовать всем странам первые 3 цифры из 10 для обозначения региона. Данной рекомендации прислушались и выполнили почти все государства, хотя в некоторых местах используются первые 4 цифры для обозначения региона. Последние семь цифр указывают уникальный номер каждого абонента.

Для проверки формата мобильного номера телефона была написана функция parse_phone, которая принимает в качестве входных данных Pandas DataFrame и номер телефона в международном формате. Вначале работы алгоритма открывается и считывается в Pandas DataFrame файл под названием «DEF-9xx.csv», который содержит Реестр российской системы и плана нумерации. В данном файле содержатся столбцы: ABC/ DEF, От, До, Емкость, Оператор, Регион, Территория ГАР и ИНН. Для работы алгоритма были выбраны столбцы: ABC/ DEF, От, До и Регион.

Работа алгоритма:

1. Открывается Реестр российской системы и плана нумерации для мобильных номеров телефона
2. Начинается построчное считывание
3. Проверяется правильность формата номера
4. Определяется страна номера
5. Если номер русский, то сопоставляются первые 3 цифры с диапазонами в плане нумерации

6. Возвращаются данные: корректность номера, страна и регион (если номер русский)

Работа алгоритма начинается с вызова функции parse_phone, которая, как было сказано выше, проверяет формат номера телефона. Если номер начинается с +7, то вызывается функция russia_num для поиска строки, в которой ABC/ DEF совпадает с 3 цифрами после кода страны и число, которое составляют остальные 7 цифр входит в диапазон От и До. Тогда регион из найденной строки будет соответствовать региону номера телефона. Если номер не российский, то вызывается функция phnum_parse, которая с помощью parse и geocoder из библиотеки phonenumbers проверяет корректность номера и страну. В данном случае регион может содержать значение «Uncnown».

Для определения места жительства по коду региона в номере телефона людей, данные которых записаны в таблице, была написана функция parse_table, принимающая на вход название таблицы с данными, название таблицы для записи результата и ограничение на количество строк - параметр limit. Если в limit передать значение 0, то будут обработаны все строки из таблицы. Данная функция была применена на предоставленных тестовых таблицах: synt_data.csv и cards.csv. Далее в отчете они будут называться таблица №1 и таблица №2 соответсвенно. После применения функции parse_table к таблице №1 и таблице №2 с параметром limit равным 0 были получены таблицы, в которых содержатся дополнительный столбец, который отвечает за регион номера телефона. На основе этих данных были построены диаграммы, представленные на рис1 и рис2. Их построение проводилось с помощью библиотеки plotly, которая позволяет создавать интерактивные графики. По итогам визуального анализа было выяснено, что таблица №1 отличается от таблицы №2 количеством человек, а также во втором случае присутствует большее количество различных регионов. По данным графикам нельзя точно сказать, что данные являются синтетическими, так как они не учитывают много других факторов, которые тоже могут помочь отличить реальные данные от




Рисунок 1

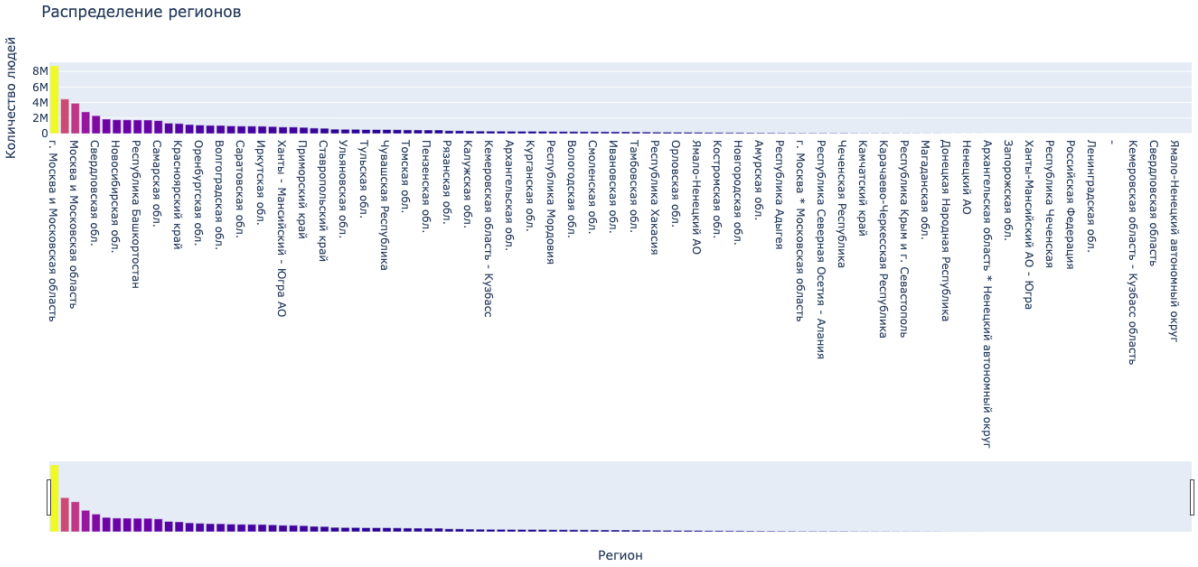



Рисунок 2

искусственно созданных. Результаты работы функции parse_table могут быть использованы в других подзадачах.

Поставленная задача по исследованию возможности сопоставления номера телефона человека с регионом выполнена в полном объеме. Результатом данной работы являются функции, способные определить регион по номеру телефона человека.

**Анализ распределения возрастов клиентов по возрастным группам**

В предыдущей задаче было сказано, что нельзя однозначно определить принадлежность данных к синтетическим на основе одного признака. Таким образом решение этой проблемы сводится к анализу совокупности критериев. По этой причине в качестве другого параметра было проведено исследование даты рождения каждого человека, а точнее его возраста на момент проведения анализа.

Для выполнения были поставлены следующие задачи:

1. Изучить различные форматы даты рождения
2. Проверить формат и вычислить возраст человека
3. Построить визуализацию распределения возраста по возрастным группам на тестовых данных
4. Проанализировать распределения
5. Найти статистику распределения людей по возрастным группам в достоверном источнике
6. Сравнить распределения, полученные на тестовых данных с достоверным источником

Были изучены различные форматы даты рождения для того, чтобы можно было преобразовать даты из таблиц в формат datetime, удобный для проведения вычисления возраста человека. Так как дата рождения была записана в таблице как строка, нужно было дополнительно проверить соответствует ли она какому-либо формату, изученному раннее. Для решения этой проблемы была использована функция parse из библиотеки dateutil, которая пытается преобразовать дату рождения из строки в тип данных datetime. Если у данной функции не получается это сделать, то она выдает исключение. После поверки формата происходит вычисление возраста человека на данный момент, то есть вычитаем дату рождения из сегодняшней даты и получаем результат. Расчет возраста происходит внутри функции countAge. Если строка является датой и

соответствует какому-либо из форматов, то функция countAge возвращает возраст человека на момент ее применения. При возникновении ошибок в формате даты она возвращает значение 0. После ее применения к таблицам №1 и №2 были получены распределения возрастов по возрастным группам. На основе этих распределений были построены графики, которые представлены на рисунках 3 и 4.

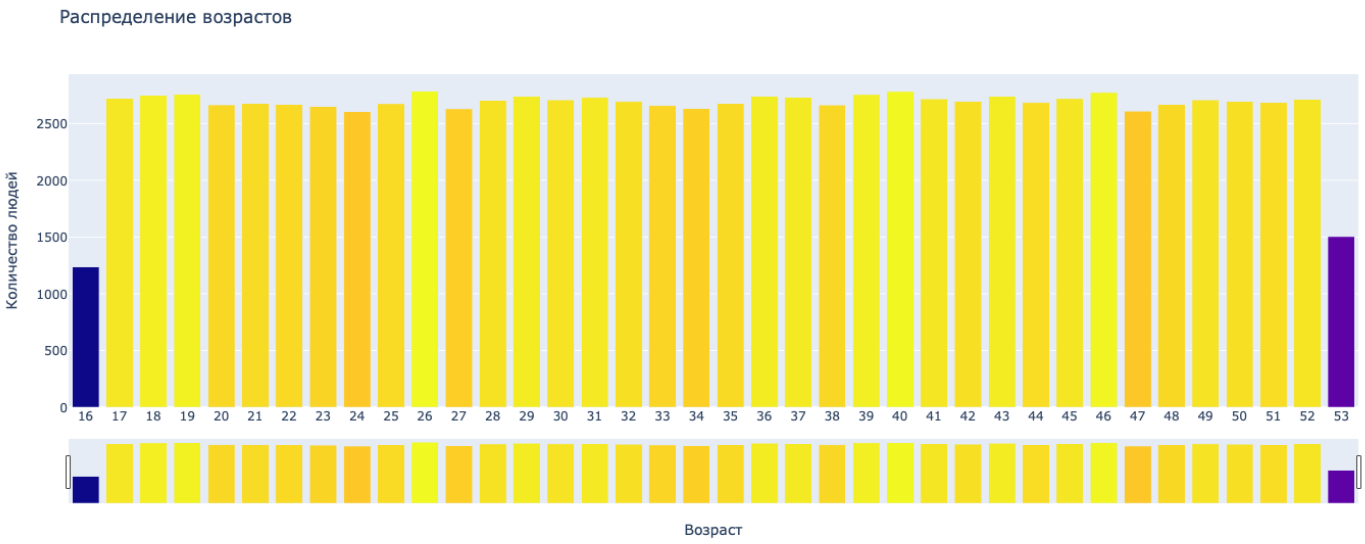



Рисунок 3

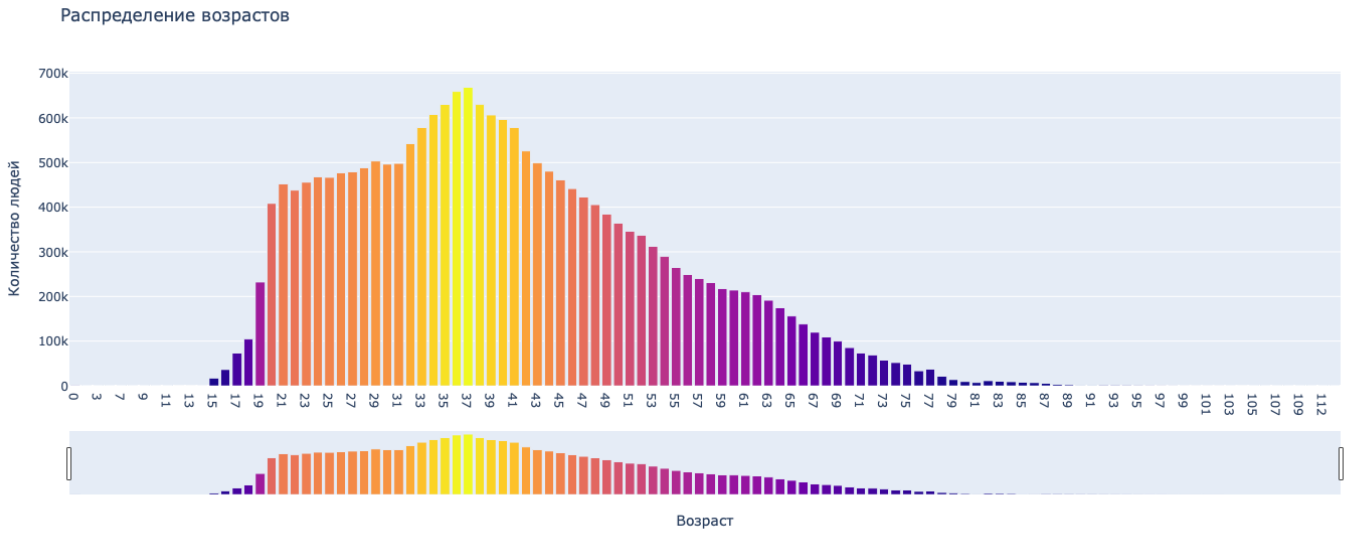



Рисунок 4

На рисунке 3 представлено распределение возрастов для таблицы №1. Визуально видно, что в первом случае возраста распределены равномерно от 17 до 52. И только граничные значения 16 и 53 выбиваются из обозначенного диапазона. На рисунке 4 можно заметить, что пик количества людей приходится на 37 лет. После этой отметки количество людей начинает равномерное снижение. Сам диапазон возрастов значительно выше и включает в себя людей от 0 до 112 лет. На основе графиков можно предположить, что данные имеют разное происхождения, так как визуально распределения различаются. Но нельзя опираться только на этот факт, нужно сравнить данные распределения статистически с достоверным источником, а также проверить нормальность распределения.

Проанализировав различные открытые источники, был выбран Росстат, так как он является официальным и достоверным источником, а также данные представлены в удобном для обработки табличном виде. В других источниках данные представлены текстовом формате, который перед использованием нужно будет дополнительно обрабатывать, или их нельзя считать достоверными, то есть сравнение с этими источниками нерационально. С официального сайта Росстата был взят архив под названием «Численность населения Российской Федерации по полу и возрасту на 1 января 2024 года». В нем находились различные таблицы с распределением людей, была выбрана таблица «1.1.1.-Таблица 1.csv», в которой содержится количество людей для каждого возраста. На основе этих данных была также построена диаграмма для визуальной оценки распределения людей по возрастным группам. Она представлена на рисунке 5.  На нем видно, что распределение не является равномерным и не похоже на рисунок 3, но его можно сравнить с рисунком 4. У них присутствует общий пик - 37 лет, который визуально заметен на диаграмме.

Как было сказано выше, нельзя сделать выводы о схожести распределений, опираясь лишь на построенные диаграммы. Также без проведения расчетов нельзя проверить распределение на нормальность. По этой причине был проведен поиск способов для их сравнения. По результатам

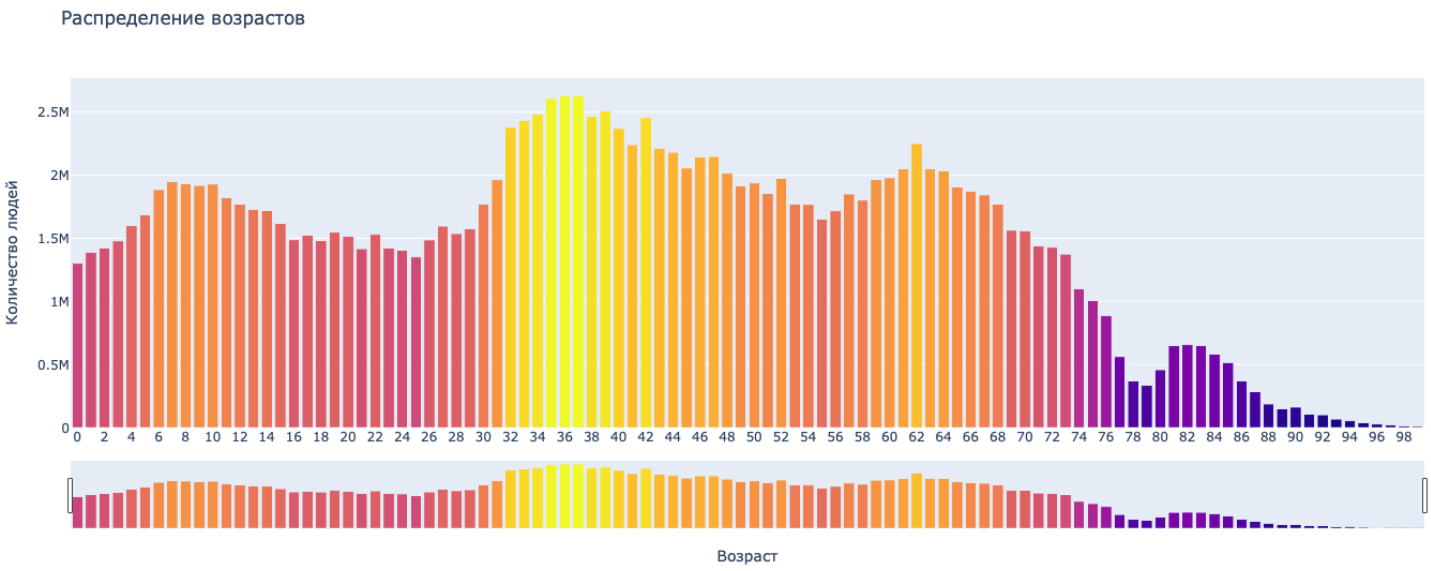



Рисунок 5

поиска был выбран тест Шапиро-Уилка для проверки на нормальность. Он используется для определения того, соответствует ли выборка нормальному распределению. Данный тип теста полезен для определения того, исходит ли данный набор данных из нормального распределения. Это является распространенным предположением, которое используется во многих статистических тестах.  Для сравнения распределений был выбран тест Колмогорова-Смирнова. Тест предназначен для определения того, что выборка имеет соответствующее распределение, но он может быть применен и в случае двух выборок. В этом случае распределение одной выборки сравнивается с распределением второй выборки и решается: имеют ли выборки одинаковое или разное распределение.

Распределения на рисунках 3, 4 и 5 имеют в сумме по всем возрастам разное количество человек, из-за этого их невозможно сравнить без дополнительных преобразований. Было принято решение сравнивать плотности распределений для каждого возраста. Это отображено на рисунке 6.

На рисунке 6 видно, что данные распределения разные. Далее представлены результаты теста Шапиро-Уилка по проверке нормальности распределений.

- Росстат: W = 0.907, p-значение = 0.000, данные значимо отклоняются от нормального распределения
- Cards (таблица №2): W = 0.840, p-значение = 0.000, данные значимо отклоняются от нормального распределения

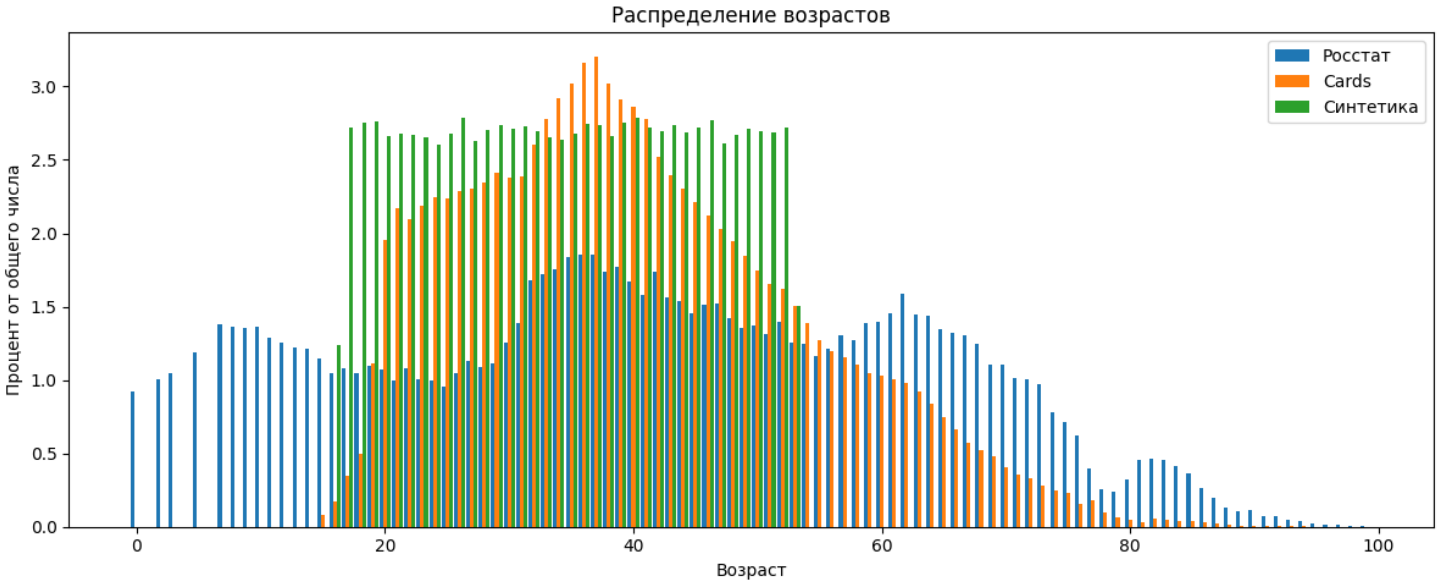



Рисунок 6

- Синтетика (таблица №1): W = 0.639, p-значение = 0.000, данные значимо отклоняются от нормального распределения

По результатам теста Шапиро-Уилка можно говорить о том, что данные распределения не соответствуют нормальному распределению.

Был проведен тест Колмогорова-Смирнова для проверки схожести распределений с Росстатом, ниже представлены результаты:

- Cards (таблица №2): p-значение: 0.0003 <= 0.05, распределения возрастов Росстата и таблицы №2 статистически различаются.
- Синтетика (таблица №1): p-значение: 0.0000 <= 0.05, распределения возрастов Росстата и таблицы №1 статистически различаются.

По результатом данного теста было выявлено, что распределения данных для таблицы №1 и таблицы №2 статистически различаются с Росстатом.

# Заключение

В рамках данной практики было проведено исследование возможности сопоставления номера телефона человека с регионом, а также был проведен анализ распределения возрастов клиентов по возрастным группам. Результатом первой задачи является алгоритм, который по номеру телефона может определить регион человека. Для второй задачи результатом является анализ распределения возрастов по различным возрастным группам. Как было сказано в отчете, задача определения принадлежности данным к синтетическим имеет высокую сложность, поэтому нельзя провести проверку на основе только одного признака. По этой причине было проведено исследование номера телефона и возраста отдельно. Их можно также изучать в совокупности с другими критериями, это сможет повысить вероятность распознания реальных данных.